

1. Çalışmanın temel araştırma sorusu nedir? (Tek cümle ile ifade et.)

Buyuk dil modellerinde quantizasyon islemi sonrasi Türkçe dilindeki morfolojik degisimler nelerdir ve Türkçenin sondan eklemeli (agglutinative) morfolojik yapısını hangi yöntem ne ölçüde korur?

2. Literatürde QulP#, GPTQ, AWQ ve OmniQuant gibi PTQ yöntemleri hangi model mimarileri üzerinde test edilmiştir?

Literatürde ağırlıklı olarak decoder-only autoregressive Transformer tabanlı LLM mimarileri üzerinde test edilmiş. Aşağıda bu yöntemlerin hangi tür modellerde test edildiğini listeledim:

1. GPTQ

GPTQ, literatürde ağırlıklı olarak decoder-only Transformer tabanlı OPT ve BLOOM model aileleri üzerinde değerlendirilmiştir; deneyler 125M'den 176B parametreye kadar uzanan ölçeklerde 3-bit ve 4-bit weight-only quantization sonuçları sunmaktadır.

([\[2210.17323\] GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers](#))

- decoder-only Transformer tabanlı OPT ve Bloom model aileleri

Model ailesi	Tür	Boyutlar
OPT	Decoder-only LLM	125M, 350M, 1.3B, 2.7B, 6.7B, 13B, 30B, 66B, 175B
BLOOM	Decoder-only LLM	560M, 1.1B, 1.7B, 3B, 7.1B, 176B

2. AWQ

AWQ, LLaMA ve LLaMA-2 gibi decoder-only Transformer LLM'lerde; ayrıca OPT, Vicuna gibi instruction-tuned modellerde ve OpenFlamingo/LLaVA gibi vision-language modellerde test edilmiştir. Temel deneyler INT3/INT4 weight-only quantization üzerindedir.

([\[2306.00978\] AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration](#))

Model / aile	Tür	Boyutlar / not
LLaMA	Decoder-only LLM	7B, 13B, 30B, 65B
LLaMA-2	Decoder-only LLM	7B, 13B, 70B
OPT	Decoder-only LLM	Özellikle ablation ve karşılaştırma deneylerinde
Vicuna	Instruction-tuned LLaMA türevi	7B ve 13B
OpenFlamingo-9B	Vision-language model	COCO captioning üzerinde
LLaVA-13B	Vision-language model	Genellenebilirlik için anılıyor

3. OmniQuant

OmniQuant, OPT, LLaMA, LLaMA-2, LLaMA-2-chat ve Falcon-180B üzerinde test edilmiştir. Literatürde hem weight-only quantization hem de weight-activation quantization ayarlarında değerlendirilen daha geniş kapsamlı PTQ yöntemlerinden biridir.

([\[2308.13137\] OmniQuant: Omnidirectionally Calibrated Quantization for Large Language Models](#))

Model ailesi	Tür	Boyutlar / not
OPT	Decoder-only LLM	125M–66B
LLaMA	Decoder-only LLM	7B–65B
LLaMA-2	Decoder-only LLM	7B–70B
LLaMA-2-Chat	Instruction-tuned chat model	Genellenebilirlik için
Falcon	Decoder-only LLM	Falcon-180B

4. QuIP#

QuIP#, ana deneylerinde LLaMA-1 ve LLaMA-2 aileleri üzerinde değerlendirilmiş; ek olarak Mixtral-8x7B ve Falcon-180B gibi farklı mimarilerde de 2-bit sonuçlar raporlanmıştır.

([\[2402.04396\] QuIP#: Even Better LLM Quantization with Hadamard Incoherence and Lattice Codebooks](#))

Model ailesi	Tür	Boyutlar / not
LLaMA-1	Decoder-only LLM	7B–65B / 70B aralığı
LLaMA-2	Decoder-only LLM	7B, 13B, 70B
Mixtral-8x7B	MoE Transformer	Appendix ek sonuç
Falcon-180B	Decoder-only LLM	Appendix ek sonuç

5. QTIP (QuiP#’ın devamı niteliğinde)

QTIP, literatürde QuiP# sonrası geliştirilen güncel bir weight-only PTQ yöntemidir. Yöntem, incoherence processing ile ağırlıkları yaklaşık Gauss dağılımına getirip Trellis-Coded Quantization kullanarak ultra-yüksek boyutlu quantization yapmayı hedefler. Deneyler ağırlıklı olarak LLaMA-1, LLaMA-2, LLaMA-3, LLaMA-3.1 Instruct ve LLaMA-3.2 Instruct ailelerinde yürütülmüş; 2-bit, 3-bit ve 4-bit weight-only quantization seviyeleri raporlanmıştır.

Genel görünüm :

Yöntem	En çok kullanılan bitler
GPTQ	4-bit, 3-bit; ayrıca 2-bit/ternary ekstrem deneme
AWQ	INT4, INT3 yani pratikte W4A16 / W3A16
OmniQuant	W4A16, W3A16, W2A16, ayrıca W6A6 / W4A4
QuiP#	2-bit, 3-bit, 4-bit; FP16 referans olarak 16-bit
QTIP	2-bit, 3-bit ve 4-bit weight-only

3. Senin önereceğin çalışma literatürde hangi boşluğu dolduracaktır?

Mevcut PTQ literatüründe yöntemler çoğunlukla İngilizce merkezli decoder-only Transformer LLM ailelerinde, özellikle OPT, BLOOM, LLaMA, LLaMA-2 ve Falcon üzerinde test edilmiştir. Türkçe

LLM'lerde ve özellikle Türkçenin eklemeli/morfolojik yapısına düşük bit quantization'ın etkisini sistematik olarak inceleyen karşılaştırmalı çalışma sınırlı görünmektedir. Bu nedenle önerilen çalışma, GPTQ, AWQ, OmniQuant ve QulP# gibi PTQ yöntemlerini Türkçe LLM'ler üzerinde aynı benchmark ve morfolojik değerlendirme protokolüyle karşılaştırarak literatürdeki bu boşluğa odaklanabilir.

4. Kullanmayı düşündüğün model(ler) ve veri set(ler)i nelerdir?

Trendyolun bazı llm modelleri olabilir, bazı 32B llm'a kökenli türkçe modeller olabilir.

- Trendyol/Trendyol-LLM-8B-T1 (**Türkçe Reasoning**)
- TURKCELL/Turkcell-LLM-7b-v1
- ytu-ce-cosmos/Turkish-Llama-8b-Instruct-v0.1
- ogulcanaydogan/Turkish-LLM-7B-Instruct
- ogulcanaydogan/Turkish-LLM-32B-Instruct
(ogulcanaydogan'ın modelleri, Qwen2.5-32B-Instruct tabanı üzerine QLoRA fine-tuning uygulanarak Türkçe instruction verisine uyarlanmıştır.)

Bu 32B Türkçe model için GGUF formatında 4-bit, 5-bit ve 8-bit quantized sürümler paylaşılmıştır. Kullanılan yöntem GPTQ/AWQ/QulP# değil, GGUF quantization presetleridir: Q4_K_M, Q5_K_M ve Q8_0. Ayrıca F16 tam hassasiyetli referans sürüm de bulunmaktadır.

“ Literatürde iyi sonuç veren PTQ yöntemleri ile, kullanıcıların gerçekten Hugging Face'ten indirip çalıştırdığı GGUF quant modeller Türkçe görevlerde nasıl fark gösteriyor? ” sorusunun cevabı çalışmamızı zenginleştireceğini düşünüyorum.

5. Hangi quantization seviyelerini karşılaştırmayı planlıyorsun?

16 (referans), 8, 4, 3, 2 bit.

6. Başarıyı hangi metriklerle değerlendireceksin?

- 1) **Perplexity (trwiki/OSCAR-tr)** — genel dil modelleme kalitesi. Ayrıca *nadir/uzun-ekli formlara öze/ perplexity* (aşağıda 8. soruda açıklıyorum).
- 2) **FP16'ya KL-divergence** — quantize modelin çıktı dağılımının orijinalden ne kadar saptığını ölçeceğim. Perplexity'den daha hassas; aynı perplexity'yi veren iki modelin davranışı çok farklı olabilir.
- 3) **Downstream görev doğruluğu** — TurkishMMLU, TR-MMLU, Mukayese alt-görevleri.
- 4) **Morfolojik metrikler** (projenin kalbi) — kök/ek doğruluğu, minimal-çift accuracy'si, morphem-F1 (ek metrik).

A) TurBLiMP minimal çift testi ([\[2506.13487\] TurBLiMP: A Turkish Benchmark of Linguistic Minimal Pairs](#))

B) Zemberek ile kök/ek analizi ([ahmetaa/zemberek-nlp: NLP tools for Turkish. · GitHub](https://github.com/ahmetaa/zemberek-nlp))

C) Uzun ekli/nadir kelimelere özel perplexity

Uzun ekli veya nadir kelimelere özel perplexity için literatürde doğrudan standartlaşmış bir Türkçe benchmark bulamadım. Bu nedenle bu kısmı sıfırdan keyfi bir liste olarak değil, trwiki/OSCAR-tr gibi mevcut Türkçe korpuslardan türetilmiş, morfolojik analizle doğrulanmış bir değerlendirme alt kümesi olarak oluşturmayı planlıyorum. Kelimeler; ek sayısı, karakter uzunluğu, tokenizer fertility değeri ve korpus frekansı gibi açık kriterlerle seçilecek. Böylece bu alt küme hem tekrarlanabilir olacak hem de çalışmanın özgün katkılarından biri hâline gelecek.

* morfem-F1

5) **Pratik maliyet** — bellek kullanımı, çıkarım hızı (token/s), quantization üretim süresi.

7. Türkçe LLM çalışılacaksa hangi benchmarkları kullanacaksın?

- **TurkishMMLU** (Yüksel et al., 2024, EMNLP Findings): 9 konuda 10.032 çoktan seçmeli soru, beş şıklı. Türkiye MEB platformu kaynaklı, kültürel olarak Türkçeye özgü — çeviri değil. Genel bilgi/akıl yürütme için ana benchmark.
(<https://aclanthology.org/2024.findings-emnlp.413/>)
- **TR-MMLU** (Bayram et al., 2024): 62 kategoride 6.200 soru; ayrıca tokenization metriklerini de içeriyor, ki bu morfoloji analizimle örtüşüyor.
(<https://arxiv.org/abs/2501.00593>)
- **Mukayese** (Safaya et al., 2022, ACL Findings): 8 görevlik kapsamlı set; dil modelleme ve segmentasyon görevleri perplexity ölçümü için de uygun.
(<https://aclanthology.org/2022.findings-acl.69/>)
- **CETVEL** (2025): 23 görev, hem ayırt edici (discriminative) hem üretici (generative) — üretim tarafı benim için önemli (8. soruya bakınız).
(<https://arxiv.org/abs/2508.16431>)
- **TUMLU**: Türki diller seti; Türkçe alt-kümesi referans karşılaştırma sağlar.
(<https://aclanthology.org/2025.acl-long.1112/> , <https://github.com/ceferisbarov/TUMLU>)

8. Morfolojik performansı nasıl ölçeceksin?

Bu, projenin en özgün ve en çok emek vereceğim kısmı. Dört ayrı yöntemle ölçeceğim ki sonuç tek bir araca bağlı kalmasın:

(a) Zemberek ile kök/ek doğruluğu: Quantize model bir metin ürettiğinde, çıktıyı Zemberek'ten geçirip kök (stem) ve ek (affix) etiketlerini FP16 referansı ile karşılaştıracam. Örneğin "kalemlerimden" kelimesi kalem + ler(çoğul) + im(iyelik) + den(ablatif) şeklinde çözümlenir; quantize model bu ek zincirini bozuyor mu, yoksa koruyor mu ? Bunu nicel olarak ölçeceğim.

(b) TurBLiMP minimal çiftleri (2025, arXiv:2506.13487): İlk Türkçe minimal çift benchmark'ı. 16 dilbilimsel olguda 1000'er çift; biri dilbilgisel doğru, diğeri tek bir morfolojik hata içeren cümleler içeriyor. Modele her ikisinin de log olasılığını hesaplatıp "doğru olana daha yüksek olasılık verebiliyor mu" diye bakacağım. FP16 ile quantize sürümler arasındaki bu yetenek farkı, morfolojik duyarlılığın ne kadar bozulduğunu doğrudan gösterir.

(c) Nadir/uzun-ekli form perplexity'si: Aynı köke bağlanan 10+ farklı çekimli formu (ör. ev → evler, evimiz, evlerimizden, evlerimizdekiler...) izole edip yalnızca bu token'larda perplexity hesaplayacağım. Genel perplexity bu nadir formları seyrelttiği için zararı gizler; izole ölçüm gerçeği gösterir.

Hesap nasıl yapılıyor: Normal perplexity, metindeki *bütün* token'ların ortalama kaybı. Bizimki aynı hesabın filtrelenmiş hali:

1. Türkçe değerlendirme metnini al (trwiki / OSCAR-tr'den bir test dilimi).
2. Her kelimeyi Zemberek'ten geçir → kök + ek zinciri çıkar.
3. Kelimeleri etiketle: ek sayısı (ör. ≥ 3 ek = "uzun ekli") ve korpus frekansı (düşük frekans = "nadir").
4. Modele metnin tamamını normal şekilde ver, her token'ın log-olasılığını al — ama ortalamayı **sadece nadir/uzun-ekli kelimelere ait token'lar üzerinden** hesapla.
5. Aynı hesabı FP16 ve her quantize sürüm için yap; farkı karşılaştır. Kontrol grubu olarak sık/kısa kelimelerin perplexity'sini de raporla — asıl bulgu ikisi arasındaki *makas*.

Ek olarak kontrollü mini-set: "ev → evler, evimiz, evlerimizden, evlerimizdekiler..." gibi aynı kökün çekim merdivenlerinden oluşan küçük, elle kurulmuş bir set de kullanabiliriz; bu, korpus gürültüsünden bağımsız bir ölçüm elde ederiz.

(d) Morphem-seviyesi metrikler (MorphBPE yöntemi, arXiv:2502.00894): Morph-Edit-Distance ve Morph-Consistency-F1 — aynı morfemi paylaşan kelimelerin tutarlı işlenip işlenmediğini ölçer.

Önemli bir metodolojik not: ölçümü hem çoktan-seçmeli (skor-tabanlı) hem de serbest-üretim (generative) modunda yapacağım. Çünkü Bielik çalışması "MC-generation dissociation" denen bir olgu belgeledi: bazı yöntemler çoktan-seçmeli skorları koruyor ama serbest üretimde çöküyor. Türkçede de bu riski test etmek için üretim-tabanlı morfolojik değerlendirme şart. (Bielik-Q2-Sharp, <https://arxiv.org/abs/2603.04162>)

9. Quantization sonrasında hangi dilsel özelliklerin daha fazla etkilenmesini bekliyorsun ve neden?

Bence burada quantizasyon işlemleri modelin sık gördüğü kalıpları korumaya, nadirleri daha da kabalaştırmaya yatkın olduğu için Türkçe eğitim verisinde düşük frekanslı olabilecek uzun ek zincirlerine sahip kelimeleri anlamlandırmada sıkıntı çıkaracağını düşünüyorum. Örneğin olumsuzluk eki almış uzun ekli "görevlendirilemeyecekmışsınız" gibi kelimeler düşük bitli quantize modellerde anlamını yitirebilir. Burada ekstra olarak Türkçedeki yüksek "fertility" oranı ile bu çökmenin devam edeceğini öngörüyorum.

Peki cokmeyi ongermek bu kadar basit neden bu calismayi yurutuyorum ????

aslinda amacim dusuk bit seviyelerinde bilgi kaybi eklemeli morfoloji uzerinde hangi mekanizmada yogunlasiyor bunu gozlemlemeye calismak.

10. Çalışmanın sonunda ortaya koymayı hedeflediğin bilimsel katkı nedir?

5 somut katkı hedefliyorum:

1. Turkce ve sondan eklemeli diller icin PTQ yontemlerinin ilk sistematik karsilastirmasi. Halihazirda literaturde boyle bir bosluk var.
2. Morfolojik koruma acisindan bir yontem siralamasi talimatları sunmak. Yani Turkce bir modeli 2-3 bite indiriyorsan morfolojiyi korumak icin su yontemi kullan diyebilecegimiz bir rehber olmasi.
3. **İki rakip literatür hipotezinin agglutinatif dilde test edilmesi.** Beklenen davranış literatür temelinde şöyle hipotezlenir:
(a) Genel perplexity ve FP16'ya KL-divergence, 4-bit'te neredeyse kayıpsız (QulP# Llama-2-7B: FP16 5.12 → 4-bit 5.19), 3-bit'te hafif (5.41), 2-bit'te uçurum (6.19; fine-tuning'siz 8.22) davranır ve Türkçede de bu genel eğri beklenir.
(b) Morfolojik metriklerin davranışı belirsizdir çünkü literatür çelişkilidir: Hooker ve Marchisio (2019, arXiv:1911.05248) / (Marchisio, arXiv:2407.03211) sıkıştırmanın uzun kuyruğu (nadir kök/çok-ekli formları) orantısız bozacağını (morfolojik metrikler daha erken çöker) öngörürken; Chang, Zhang, Thomason & Jia (2025, EMNLP, arXiv:2506.12044) tam tersine 3–4 bit'te uzun-kuyruk örneklerinin görece olarak daha az etkilendiğini bulmuştur. Çalışmamız bu doğrudan çelişkiye Türkçe morfolojisi üzerinden ampirik kanıt sağlar.
4. Bu calismada biz sabit bir modelin base ve quantize hallerinin kiyaslamasina girecegiz fakat inceledigim ptq makalelerinde hem bunu hem de sabit bit boyutunda

en iyi bit-parametre kombinasyonu nedir sorusu araştırılmış (örn: toplam 120 milyar bit kapasitede; llama2 2-bit 60B ✓ vs llama2 3-bit 40B ✗). Bu da sabit kaynaktan en iyi zeka kombinasyonu nasıl tutulur bize veren bulgu olmuş bu noktada biz ne yapabiliriz bunu düşünüyorum.



(opsiyonel , ciddi)

5. Mekanizma katkısı: morfolojik bilginin katman/bileşen haritası. Bozulma eğrisini betimlemekle yetinmeyip, neden sorusuna seçici (selective) quantization deneyleriyle yaklaşacağız.

Yöntem şu: modelin tamamı düşük bit'e indirilirken belirli bir katman bloğu veya bileşen tipi (ör. tüm MLP down_proj matrisleri) FP16'da tutulur ve bunun morfolojik metrikleri ne ölçüde "kurtardığı" ölçülür; simetrik olarak, yalnızca tek bir grubun quantize edildiği ters deney de yapılır. Hesap yükünü yönetilebilir kılmak için katmanlar erken/orta/geç bloklara, bileşenler tipe göre gruplanacaktır. Literatürde bu tür hassasiyet analizleri hasarı perplexity ile ölçmektedir ve Llama/Mistral ailesinde erken katmanlar ile MLP down_proj/v_proj bileşenlerinin en kırılgan olduğu raporlanmıştır (arXiv:2604.19884); Chang et al. (2025, arXiv:2506.12044) ise quantization hatasının düzeltilmesinde üst-katman MLP gate çıktıların kritik rol oynadığını göstermiştir. Bizim özgün katkımız, hasar metriği olarak perplexity yerine morfolojik metrikleri (TurBLiMP, kök/ek doğruluğu, nadir-form perplexity) kullanmak ve böylece "genel dil kalitesini taşıyan bileşenler" ile "Türkçe morfolojisini taşıyan bileşenler" haritalarının örtüşüp örtüşmediğini ilk kez test etmektir. Haritalar ayrışır, morfolojik bozulmanın mekanizmasına dair somut bir bulgu elde edilir; örtüşürse, morfolojinin genel dil yeteneğinden ayrı bir alt-devrede taşınmadığı yönünde yine bilgilendirici bir sonuç doğar. Bu analiz, tensor-bazında quantization kontrolüne izin veren esnek araçlarla (llama.cpp özel quant kuralları, HQQ katman-bazlı bit ayarı) hasarın belirgin olduğu 2-3 bit rejiminde yürütülecektir.

Notlar:

“QulP# significantly outperforms existing PTQ methods including OmniQuant (Shao et al., 2024), QulP (Chee et al., 2023) (a previous, separate work), and AQLM (Egiazarian et al., 2024). To the best of our knowledge, QulP# is also the first PTQ method where 3-bit models scale better than 4-bit models. This directly refutes Dettmers & Zettlemoyer (2023)’s claim that 4-bit models are “optimal” and indicates that as the field of PTQ develops, 2-bit models are likely to scale better than 3-bit models in the near future. ” (<https://arxiv.org/pdf/2402.04396>)

Kaynaklar:

[1] (Marchisio, <https://arxiv.org/abs/2407.03211>) → quantization'ın çok dilli modellerde düşük kaynaklı dilleri orantısız vurduğunu, otomatik metriklerin zararı küçümsediğini (Japonca'da otomatik %1.7 → insan değerlendirmesinde %16) gösteren çalışma. TurBLiMP/morfoloji hipotezindeki "uzun kuyruk orantısız bozulu" öngörüsünün kaynağı bu.

[2] (Dettmers & Zettlemoyer , <https://arxiv.org/abs/2212.09720>) → **"4 bit optimal nokta"**

[3] AQLM (Vage Egiazarian, Andrei Panferov .. <https://arxiv.org/abs/2401.06118>)

[4] Bielik-Q2-Sharp (<https://arxiv.org/abs/2603.04162>) → bazı yöntemler çoktan-seçmeli skorları koruyor ama serbest üretimde çöküyor.